Évaluation des coûts d'infrastructure

Capacite provisionnee, couts variables et marges de reduction

Plateforme SIVAX — infrastructure Amazon Web Services
Document établi à partir de l'inventaire du compte AWS.

Version du 9 septembre 2026. Ce document chiffre le coût de fonctionnement de la plateforme SIVAX sur Amazon Web Services. Il remplace l'évaluation établie pour la précédente infrastructure Azure, qui n'a plus d'objet depuis la bascule du 8 septembre 2026.

Méthode

Deux précautions distinguent ces chiffres d'une estimation faite au catalogue :

- **L'inventaire vient du compte**, non du code. Chaque ressource a été relevée par interrogation directe de l'API AWS sur les deux régions. Ce qui est chiffré est donc ce qui tourne réellement — y compris ce que personne n'avait demandé, et qui était facturé quand même.
- **Les prix viennent de l'API de facturation d'AWS**, région par région. Paris et Francfort ne sont pas au même tarif, et l'écart se voit sur les postes lourds.

Base de calcul : 730 heures par mois, tarif à la demande, sans engagement de durée. Montants exprimés en dollars américains, devise de facturation d'AWS.

Synthèse

Environnement	Région	USD par mois
Développement	eu-west-3 (Paris)	233
Production	eu-central-1 (Francfort)	474
Total		**707**

Ces montants couvrent la capacité provisionnée. Ils excluent les coûts liés au volume de trafic, détaillés plus loin, ainsi que les services facturés hors AWS — l'API du fournisseur de modèles de langage au premier chef.

À titre de comparaison, l'enveloppe visée sur l'infrastructure Azure précédente était d'environ 800 dollars par mois pour les deux environnements. La bascule n'alourdit donc pas la dépense ; elle ne l'allège pas non plus de façon significative, et les marges de réduction identifiées tiennent au dimensionnement plutôt qu'au choix du fournisseur.

Développement — eu-west-3 (Paris)

Poste	Base de calcul	USD par mois
Plan de contrôle Kubernetes	0,100 × 730	73,00
Nœuds — 2 × t3a.medium	2 × 0,0425 × 730	62,05
Disques des nœuds — 80 Go	80 × 0,0928	7,42
Base de données — db.t4g.micro	0,018 × 730	13,14
Stockage de la base — 20 Go	20 × 0,133	2,66
Passerelle NAT	0,050 × 730	36,50
Load balancer applicatif	0,02646 × 730	19,32
Adresses IPv4 publiques — 3	3 × 0,005 × 730	10,95
Secrets — 10	10 × 0,40	4,00
Registre d'images — 0,35 Go	0,35 × 0,10	0,04
Journaux	estimation	3,00

Poste	Base de calcul	USD par mois
Stockage objet	estimation	0,50
Total		**232,58**

Production — eu-central-1 (Francfort)

Poste	Base de calcul	USD par mois
Plan de contrôle Kubernetes	0,100 × 730	73,00
Nœuds système — 2 × t3a.medium	2 × 0,0432 × 730	63,07
Nœuds applicatifs — 2 × t3a.large	2 × 0,0864 × 730	126,14
Disques des nœuds — 160 Go	160 × 0,0952	15,23
Base de données — db.t4g.small	0,037 × 730	27,01
Stockage de la base — 50 Go	50 × 0,137	6,85
Passerelles NAT — 3	3 × 0,052 × 730	113,88
Load balancer applicatif	0,027 × 730	19,71
Adresses IPv4 publiques — 6	6 × 0,005 × 730	21,90
Secrets — 10	10 × 0,40	4,00
Registre d'images — 0,35 Go	0,35 × 0,10	0,04
Journaux	estimation	3,00
Stockage objet	estimation	0,50
Total		**474,33**

Ce qui varie avec l'usage

Ces postes dépendent du trafic réel et non de la capacité réservée. Ils s'ajoutent aux montants ci-dessus, dans des proportions modestes au volume actuel.

Poste	Tarif	Facteur déterminant
Données traitées par les passerelles NAT	0,050 à 0,052 USD par Go	la synchronisation quotidienne SNIS RDC
Capacité du load balancer	environ 0,008 USD par unité-heure	nombre de connexions simultanées
Transfert sortant vers Internet	0,09 USD par Go au-delà de 100 Go	poids des pages servies
Ingestion des journaux	0,50 USD par Go	niveau de journalisation retenu

Ce qui ne génère aucun coût

- **La chaîne de livraison.** Elle s'exécute sur GitHub Actions, dont le forfait gratuit couvre 2 000 minutes par mois pour un dépôt privé. Un déploiement complet en consomme environ six, soit près de trois cents

déploiements mensuels compris dans le forfait.

- **Le service de construction d'images d'AWS**, provisionné mais inactif : le compte n'autorise pas encore son exécution. Le jour où cette limite sera levée, compter quelques centimes par déploiement.
- **L'agent de déploiement continu** et la construction d'images dans le cluster, qui s'exécutent sur des machines déjà facturées.
- **La gestion du nom de domaine**, restée chez l'hébergeur actuel.

Optimisation réalisée

Cinq adresses IPv4 publiques étaient facturées sans être rattachées à aucune ressource — deux en développement, trois en production — pour **18,25 dollars par mois**. Il s'agissait d'adresses réservées pour une variante d'architecture finalement écartée, le compte AWS n'autorisant pas le type de load balancer correspondant. AWS facturant toute adresse IPv4 publique depuis février 2024, qu'elle serve ou non, une adresse inutilisée coûtait exactement autant qu'une adresse en service.

Ces adresses ont été libérées, et le bon fonctionnement des deux environnements vérifié après l'opération. Les montants du présent document en tiennent compte ; ils s'élevaient à 725 dollars avant cette correction.

Un audit du compte a été mené dans la même passe, à la recherche d'autres postes facturés sans contrepartie : volumes de stockage détachés, load balancers résiduels, sauvegardes manuelles oubliées, images de conteneurs orphelines. Aucun n'a été trouvé. **Tout ce qui reste facturé sert.**

Marges de réduction identifiées

Les deux pistes ci-dessous ne relèvent pas du nettoyage : chacune échange de la dépense contre de la résilience. Elles appellent donc une décision, non une application automatique.

Dimensionnement des nœuds applicatifs — jusqu'à 133 USD par mois

Les applications de production réservent au total 610 millicœurs, sur 8 cœurs provisionnés. Le groupe de nœuds applicatifs représente 126 dollars de calcul et 8 dollars de disque par mois.

Deux options, de portée différente : ramener ces nœuds à la taille employée en développement économise environ 63 dollars par mois tout en conservant la séparation entre applications et modules du cluster ; supprimer entièrement le groupe économise 133 dollars, au prix de cette séparation.

L'une comme l'autre suppose un remplacement des nœuds, donc une brève interruption à programmer.

Passerelles NAT de production — 75,92 USD par mois

La production dispose d'une passerelle par zone de disponibilité. Deux d'entre elles pourraient être supprimées. Ce n'est pas du gaspillage : cette redondance garantit qu'une panne affectant une zone ne prive pas les deux autres de leur accès à Internet — donc à SNIS RDC. La question est de savoir si ce niveau de disponibilité est requis au regard des usages.

Les deux mesures cumulées ramèneraient la dépense mensuelle d'environ 707 à **500 dollars**.

Suivi budgétaire : à activer

Quatre alarmes techniques sont configurées par environnement, et un budget de dépense mensuel est prévu dans la configuration — 250 dollars en développement, 500 en production.

Ni les unes ni l'autre ne préviennent actuellement qui que ce soit. Le canal de notification ne compte aucun destinataire, et le budget n'est de ce fait pas créé. Renseigner une ou plusieurs adresses de courriel dans la configuration active les deux d'un seul geste.

Deux remarques sur les seuils, une fois cette activation faite. Les montants prévus, 250 et 500 dollars, sont très proches de la dépense réelle : le seuil d'alerte à 80 % serait franchi dès le premier mois complet. L'ordre à suivre est donc d'appliquer d'abord les réductions retenues, puis d'ajuster les budgets à la dépense qui subsiste — relever les seuils sans toucher aux dépenses reviendrait à faire taire l'instrument plutôt qu'à traiter ce qu'il mesure.

Périmètre non couvert

- **L'API du fournisseur de modèles de langage**, facturée à l'usage indépendamment d'AWS. C'est le poste susceptible de croître sans qu'aucune capacité n'ait été réservée, puisqu'il suit le nombre de questions posées à l'assistant.
- **La plateforme Supabase**, sur son propre abonnement.
- **L'hébergement du domaine**, qui porte le service de noms, la messagerie et la redirection du nom racine.