Évaluation des coûts Azure

Plateforme diav1 — environnements dev et prod

13 jours d'exploitation (16 au 28 août 2026) — service interrompu par la désactivation de l'abonnement

~167 €	13,50 €	505 €	217 €
consommés en 13 jours (16 au 28 août)	par jour en régime établi	par mois au plancher des deux environnements	par mois même clusters éteints

En une phrase

La plateforme a été dimensionnée pour un budget de 800 €/mois et coûte effectivement entre 505 et 593 €/mois : c'est conforme au modèle. Le problème n'est pas le montant mensuel, c'est la **vitesse de consommation rapportée à un abonnement à crédit**. À 13,50 € par jour, un crédit d'essai de 200 USD est épuisé en une quinzaine de jours — ce qui correspond exactement à la durée de vie observée de l'abonnement, déployé le 16 août et désactivé le 28.

1. Le fait déclencheur

Le 28 août 2026, toute écriture sur l'abonnement est refusée avec le code `ReadOnlyDisabledSubscription`. Les deux environnements sont hors ligne simultanément : le pool de nœuds `user` est en `provisioningState: Failed` dans les deux clusters et l'ingress n'a plus de backend, tandis que les IP publiques, l'ACR et les Key Vault répondent toujours. Aucun code n'a été poussé depuis le 26 août, date du dernier déploiement complet et réussi. La cause est donc financière, pas technique.

Un point d'architecture aggrave la portée de l'incident : dev et prod partagent le **même abonnement** (`acf4a7fb-…-16ae927828e4`, intitulé « prod »), malgré des régions distinctes. Il n'existe aucune isolation de facturation entre les deux : un incident de paiement coupe la production et l'environnement de développement au même instant.

2. Ce qui est déployé

Inventaire confirmé en lecture directe sur l'abonnement le 28 août. Les volumes et les SKU proviennent du code Terraform (`infra/envs/*/main.tf`), les prix unitaires de l'API Azure Retail Prices, en euros, tarif à la consommation.

Composant	dev — francecentral	prod — swedencentral
Cluster AKS	aks-diav1-dev-frc, v1.34, tier Free	aks-diav1-prod-sdc, v1.34, tier Free
Serveur d'API	public	privé (private endpoint)
Pool système	1 × Standard_D2s_v6, taille fixe	1 × Standard_D2s_v6, taille fixe
Pool applicatif	1 × Standard_D2s_v6, taille fixe	1 × Standard_D2s_v6, autoscale 1 à 2
Disques OS	128 Go Premium SSD par nœud	128 Go Premium SSD par nœud
PostgreSQL	Standard_B1ms, 32 Go, PG 16	Standard_B2s, 64 Go, PG 16
Sauvegardes	7 jours, sans géo-redondance, sans HA	7 jours, sans géo-redondance, sans HA
Registre	ACR Basic	ACR Basic
Réseau	VNet, NAT Gateway, 2 IP publiques, 6 zones DNS privées	identique
Observabilité	Log Analytics + Application Insights	identique

Composant	dev — francecentral	prod — swedencentral
Front Door / WAF	non provisionné (quota à 0)	non provisionné (quota à 0)
Azure OpenAI	non provisionné (API externe)	non provisionné (API externe)

94 ressources au total. Trois postes coûteux ont déjà été écartés à la conception : Front Door, Azure OpenAI et Container Insights — ce dernier réservait à lui seul plus de ressources que l'application elle-même.

3. Coût unitaire, environnement par environnement

Base de calcul : 730 heures par mois.

dev — francecentral

Poste	€ / mois	€ / jour
2 nœuds AKS D2s v6 à 0,1036 €/h	151,26	4,97
2 disques OS P10 128 Go	41,86	1,38
NAT Gateway (passerelle + données)	37,50	1,23
PostgreSQL B1ms à 0,0167 €/h	12,19	0,40
2 IP publiques statiques	6,42	0,21
Log Analytics + Application Insights	6,20	0,20
ACR Basic	2,30	0,08
DNS privé, Key Vault, divers	2,50	0,08
Sous-total dev	**260**	**8,56**

prod — swedencentral

Poste	2 nœuds (plancher)	3 nœuds (plafond)
Nœuds AKS D2s v6 à 0,0939 €/h	137,09	205,64
Disques OS P10 128 Go	38,05	57,08
NAT Gateway	32,00	32,00
PostgreSQL B2s à 0,0349 €/h	25,48	25,48
2 IP publiques statiques	6,42	6,42
ACR Basic, Log Analytics, DNS, Key Vault	5,80	5,80
Sous-total prod	**245**	**332**

Périmètre complet	€ / mois	€ / jour
Plancher — prod au repos (2 nœuds)	505	16,61
Plafond — prod à sa capacité maximale (3 nœuds)	593	19,50
Budget fixé au départ	800	26,30

L'écart de 88 € entre plancher et plafond est exactement le prix de l'élasticité de prod : un nœud applicatif supplémentaire et son disque. Le plafond reste sous le budget cible, avec environ 25 % de marge.

4. Confrontation du modèle à la facturation réelle

Consommation relevée dans Cost Management sur les trois premiers jours, les seuls mesurés directement :

Jour	Total	dev	prod (swedencentral)	prod frc (supprimé)
16/08	0,61 €	0,61 €	–	–
17/08	17,73 €	11,69 €	–	6,03 €
18/08	13,39 €	7,07 €	6,17 €	0,16 €

Le 18 août est la première journée complète avec l'empreinte actuelle : **13,39 €**, dont 7,07 € pour dev, soit 212 €/mois — en dessous des 260 € du modèle. L'écart vient des paliers gratuits : plan de contrôle AKS en tier Free, premiers gigaoctets de Log Analytics offerts. Le modèle du chapitre 3 est donc un **majorant honnête** : la facture réelle se situe dans le bas de la fourchette, autour de 450 à 550 €/mois.

5. Consommation cumulée sur les 13 jours

Période	Nature du chiffre	Montant
16 au 18/08	mesuré (Cost Management)	31,73 €
19 au 27/08 (9 jours)	extrapolé à 13,50 €/jour	121,50 €
28/08 (journée partielle)	extrapolé, jusqu'à la désactivation	13,50 €
Total consommé depuis le premier apply		**~167 €**
Équivalent en dollars	au taux de 1,08 USD/€	~180 USD

> **L'hypothèse la plus probable sur la désactivation**
> 180 USD consommés en 13 jours est très proche des 200 USD de crédit d'un essai Azure gratuit, et la date d'épuisement calculée tombe sur le 28 août — le jour même de la coupure. L'autre lecture possible est un abonnement à la consommation dont le moyen de paiement a été rejeté. Les deux mènent au même constat opérationnel, mais pas au même remède : il faut lever le doute dans Cost Management avant de réactiver.

6. Durée de vie d'un crédit, selon le train de dépense

Nombre de jours avant épuisement, pour trois dotations courantes. C'est la lecture qui compte lorsque la plateforme est financée par crédit plutôt que par facture.

Train de dépense	185 € (essai 200 USD)	925 € (1 000 USD)	4 600 € (5 000 USD)
19,50 €/j — plafond des deux environnements	9 jours	47 jours	236 jours
16,61 €/j — plancher des deux environnements	11 jours	56 jours	277 jours
13,50 €/j — régime observé	**14 jours**	**69 jours**	**341 jours**
8,05 €/j — prod seule, dev détruit	23 jours	115 jours	571 jours
7,13 €/j — tout éteint (parking)	26 jours	130 jours	644 jours

7. Le coût de l'inaction : éteindre ne suffit pas

Arrêter les clusters (`az aks stop`) désalloue les machines virtuelles et met fin à leur facturation, mais laisse courir tout le reste. C'est le chiffre le plus souvent sous-estimé :

Poste conservé même à l'arrêt	dev	prod	Total
Disques OS des nœuds	41,86	38,05	79,91

Poste conservé même à l'arrêt	dev	prod	Total
NAT Gateway	37,50	32,00	69,50
PostgreSQL (le stockage reste facturé)	12,19	25,48	37,67
IP publiques statiques	6,42	6,42	12,84
ACR, Log Analytics, DNS privé, Key Vault	11,00	5,80	16,80
Total mensuel en parking	**108,97**	**107,75**	**217**

Autrement dit : suspendre la plateforme économise environ 57 % de la facture, pas 100 %. Seul un `terraform destroy` ramène le coût à zéro — et c'est précisément ce que les critères d'acceptation de dev prévoient, avec une reconstruction complète en moins de 45 minutes sans intervention manuelle.

8. Leviers d'économie, par rendement décroissant

Levier	Économie par mois	Coût de mise en œuvre	Réversible
Détruire dev, le reconstruire à la demande	260 €	45 min de reconstruction par cycle	oui
Éteindre dev nuits et week-ends (env. 66 % des heures)	100 €	une planification à écrire	oui
Disques OS 64 Go Standard SSD au lieu de 128 Go Premium	60 €	recréation des pools de nœuds	oui
Supprimer la NAT Gateway de dev	37 €	revoir la sortie Internet de dev	oui
Réservation 1 an sur les nœuds de prod (–40 %)	55 €	engagement ferme de 12 mois	non

Scénario	€ / mois	€ / jour
Statu quo — dev + prod au plancher	505	16,61
dev éteint hors heures ouvrées	405	13,32
dev détruit, prod seule	245	8,05
dev détruit + disques réduits + réservation prod	**170**	**5,59**
Tout en parking (clusters arrêtés)	217	7,13
Tout détruit (seul le tfstate subsiste)	< 1	–

La réservation d'instances n'a de sens qu'une fois l'empreinte stabilisée et la facturation assainie : c'est un engagement de douze mois, il serait prématuré de le prendre sur un abonnement qui vient d'être désactivé.

9. Recommandations

#	Action	Effet attendu	Délai
1	Établir la nature de l'abonnement dans Cost Management — crédit d'essai épuisé ou paiement rejeté — avant toute réactivation	lève l'ambiguïté sur le remède	immédiat
2	Renseigner `alert_emails` dans les deux fichiers `terraform.tfvars` : la liste est vide, donc les budgets de 250 et 500 €/mois déjà déclarés n'ont **aucun destinataire**	supprime l'angle mort qui a conduit à la coupure	immédiat
3	Ajouter une alerte sur le crédit restant à 50 %, 80 % et 100 %, et pas seulement sur le budget mensuel	prévient l'épuisement, pas seulement le dépassement	court terme
4	Séparer la facturation de dev et de prod, ou à défaut acter explicitement que les deux tombent ensemble	supprime le risque de coupure globale	à arbitrer

#	Action	Effet attendu	Délai
5	Appliquer les leviers 1 à 3 du chapitre 8 si le financement reste sur crédit : ils ramènent le train de dépense de 13,50 à environ 5,60 €/jour	multiplie par 2,4 la durée de vie du crédit	court terme

Le point le plus important

Les budgets Azure de 250 € (dev) et 500 € (prod) sont bien déclarés dans le code, et le groupe d'action existe. Mais il construit ses destinataires par itération sur `alert_emails`, qui vaut `[]` dans les deux environnements. Les alertes se sont donc déclenchées dans le vide jusqu'à la désactivation. Une ligne de configuration sépare la situation vécue d'un simple courriel d'avertissement reçu à temps.

10. Hors périmètre de cette évaluation

La facture Azure ne couvre pas les services externes, facturés séparément et non inclus dans les montants ci-dessus : l'API OpenAI (choix assumé plutôt qu'Azure OpenAI, facturée à l'usage), Supabase (authentification et tables ETL), Resend (envoi de courriels), ElevenLabs (synthèse vocale), le domaine sivax.health chez Hostinger, et Azure DevOps — un agent hébergé gratuit, suffisant aujourd'hui.

11. Méthode et réserves

Ce qui est mesuré : l'inventaire des ressources, vérifié en lecture directe sur l'abonnement le 28 août ; les SKU et les volumes, lus dans le code Terraform ; la consommation réelle des 16, 17 et 18 août, relevée dans Cost Management.

Ce qui est estimé : la consommation du 19 au 28 août, extrapolée à partir de la première journée complète (13,50 €/jour), faute d'accès à la facturation détaillée sur cette période. Le cumul de 167 € doit donc être lu comme une fourchette de 160 à 200 €. La nature de l'abonnement et le montant exact du crédit ne sont pas connus : l'hypothèse de l'essai à 200 USD est cohérente avec les dates, elle n'est pas établie.

Pour lever les réserves, une fois l'abonnement lisible : ouvrir Cost Management puis Analyse des coûts, sur la période du 16 au 28 août, avec un regroupement par groupe de ressources. Le total réel remplacera l'extrapolation et confirmera ou infirmera l'hypothèse du crédit épuisé.

Sources : inventaire de l'abonnement du 28/08/2026 ; `infra/envs/dev/main.tf` et `infra/envs/prod/main.tf` ; `livrables/RUNBOOK-MISE-A-JOUR.md`, chapitre 6 ; API Azure Retail Prices (EUR, tarif à la consommation, base 730 h).